

**TECHNICKÁ UNIVERZITA V KOŠICIACH**  
**KATEDRA KYBERNETIKY A UMELEJ INTELIGENCIE**

**SVM**

**2025**

**Danil Kozhan**

## Abstrakt v SJ

Táto dokumentácia popisuje implementáciu klasifikátora Support Vector Machine (SVM) od teoretických základov až po praktickú realizáciu v jazyku C++ bez použitia externých knižníc. Projekt sa zameriava na klasifikáciu zvukových nahrávok ako hip-hop alebo klasická hudba na základe extrahovaných vlastností. Dataset bol predspracovaný pomocou prieskumnej analýzy, výberu príznakov a Min-Max škálovania. Vlastný model SVM bol natrénovaný pomocou gradientného zostupu a L2 regularizácie. Následne bol integrovaný do grafického rozhrania (GUI) vytvoreného v CustomTkinter, ktoré umožňuje používateľom nahrať zvukové súbory a získať výsledky klasifikácie žánru v reálnom čase.

## Kľúčové slova v SJ

SVM, Klasifikátor Podporných Vektorov, Strojové Učenie, Učenie s učiteľom, C++, binárna klasifikácia, analýza zvukových dát

## Abstrakt v AJ

This documentation describes the implementation of a Support Vector Machine (SVM) classifier from theoretical foundations to practical execution in C++, without using external libraries. The project involves classifying audio recordings into hip-hop or classical music based on extracted features. The dataset was preprocessed through exploratory data analysis, feature selection, and Min-Max scaling. A custom SVM model was trained using gradient descent and L2 regularization. The trained model was then integrated into a graphical user interface (GUI) built with CustomTkinter, enabling users to upload audio files and receive real-time genre classification results.

## Kľúčové slova v AJ

SVM, Support Vector Classifier, Machine Learning, Supervised Learning, C++, Binary classification, Audio data analysis

# Obsah

|                                                          |    |
|----------------------------------------------------------|----|
| Zoznam obrázkov .....                                    | 4  |
| Úvod .....                                               | 5  |
| 1. Formulácia úlohy a cieľ práce.....                    | 6  |
| 2. Teoretický rozbor .....                               | 7  |
| 3. Implementácia riešenia .....                          | 12 |
| 3.1. Spracovanie a analýza dát.....                      | 12 |
| 3.2. Implementácia algoritmu a dosiahnuté výsledky ..... | 12 |
| 3.3. Implementácia predikčného skriptu .....             | 13 |
| 3.4. Implementácia používateľského rozhrania.....        | 13 |
| Záver.....                                               | 15 |
| Zoznam použitej literatúry .....                         | 16 |

## Zoznam obrázkov

|                                                                      |    |
|----------------------------------------------------------------------|----|
| Obrázok 1: Príklad rozhodovacej hyperplochy v priestore prvkov ..... | 7  |
| Obrázok 2: Vizualizácia cieľa optimalizácie SVM.....                 | 8  |
| Obrázok 3: Režim celej obrazovky AlcoustIQ.....                      | 14 |

## Úvod

Klasifikácia hudobných žánrov je dôležitou úlohou v oblasti spracovania zvuku a strojového učenia. V praxi sa často využívajú hlboké neurónové siete, avšak ich výpočtová náročnosť nie je vždy efektívna. Preto má význam skúmať metódy s nižšou zložitou, ako je Support Vector Machine (SVM).

Cieľom tejto práce je navrhnúť a implementovať binárny klasifikátor hudobných žánrov založený na SVM s dôrazom na efektívnosť a presnosť predikcie. Bol použitý GTZAN Music Genre Dataset, pričom boli analyzované korelácie medzi príznakmi a cieľovou premennou pre optimalizáciu výberu dát. Implementácia zahŕňa spracovanie dát, tréning modelu v C++, vytvorenie predikčného skriptu a návrh grafického rozhrania v Pythone.

Práca čerpá z odborných zdrojov, ako MIT OpenCourseWare a Scikit-learn dokumentácia, a je rozdelená na teoretickú a implementačnú časť. Teoretická časť vysvetľuje princípy SVM, optimalizáciu s využitím Lagrangeových multiplikátorov a jadrové metódy. Implementačná časť opisuje proces predspracovania dát, tréning modelu, predikciu a návrh používateľského rozhrania.

## 1. Formulácia úlohy a cieľ práce

Cieľom tejto práce je návrh a implementácia binárneho klasifikátora hudobných nahrávok založeného na algoritme Support Vector Machines (SVM) v jazyku C++. Hlavná úloha spočíva v spracovaní zvukových dát, extrakcii relevantných príznakov a vytvorení modelu, ktorý dokáže spoľahlivo rozlišovať medzi dvoma hudobnými žánrami – hip-hop a klasická hudba.

1. Prieskumná analýza dát (EDA) – údaje zo súboru GTZAN budú spracované a filtrované na požadované hudobné žánre. Bude vykonaná analýza údajov a korelačná analýza príznakov.
2. Implementácia SVM modelu – model SVM bude implementovaný bez použitia externých knižníc strojového učenia. Tréning bude prebiehať pomocou gradientného zostupu a L2 regularizácie na optimalizáciu váh a zabránenie overfittingu.
3. Hodnotenie modelu – presnosť klasifikátora bude validovaná na testovacích dátach, pričom sa vyhodnotia metriky úspešnosti klasifikácie. Hyperparametre modelu budú optimalizované pomocou metódy Grid Search.
4. Vývoj používateľského rozhrania – implementácia grafického rozhrania v CustomTkinter umožní používateľom nahráť zvukový súbor a získať výsledok klasifikácie v reálnom čase. Používateľské rozhranie zabezpečí jednoduchú interakciu s modelom bez potreby znalostí programovania.

Výsledkom tejto práce bude plne funkčný systém schopný klasifikovať hudobné skladby do jednej z dvoch kategórií. Dokumentácia detailne popisuje každý krok implementácie a poskytuje návod na použitie vytvoreného modelu.

## 2. Teoretický rozbor

Support Vector Machines (SVM) sú algoritmy učenia pod dohľadom, ktoré sa využívajú na klasifikáciu aj regresiu. Princípom SVM je nájdenie optimálnej hyperplochy, ktorá rozdeľuje jednotlivé triedy v dátach tak, aby sa maximalizovala marža medzi najbližšími dátovými bodmi každej triedy. Táto marža je definovaná ako vzdialenosť medzi rozhodovacou hyperrovinou a podpornými vektormi – dátovými bodmi, ktoré určujú jej polohu [1].

Matematicky môžeme hyperrovinou v  $n$ -rozmernom priestore vyjadriť ako:

$$w \cdot x + b = 0 \quad (1)$$

kde:


- $w$  je vektor váh,
- $x$  je vstupný vektor,
- $b$  je bias (posun hyperroviny).

Pre binárnu klasifikáciu sú triedy definované ako  $y \in \{-1, 1\}$  a správne klasifikované body musia splniť podmienku:

$$y_i(w \cdot x_i + b) \geq 1 \quad (2)$$

kde:

- $y_i = 1$  pre pozitívne vzorky,  $y_i = -1$  pre negatívne vzorky



Obrázok 1: Príklad rozhodovacej hyperplochy v priestore prvkov

Marža je vzdialenosť medzi podpornými vektormi, čím je väčšia, tým lepšie a všeobecnejšie sú údaje oddelené. Matematicky možno maržu vyjadriť nasledovne [2]:

$$width = (\bar{x}_+ - \bar{x}_-) \cdot \frac{\bar{w}}{\|\bar{w}\|},$$

kde:

- $\bar{x}_+$  je vektor príznačkov podporného vektora kladnej triedy.
- $\bar{x}_-$  je vektor príznačkov podporného vektora zápornej triedy.
- $\bar{w}$  je normálový vektor (vektor váh) definujúci orientáciu oddeľovacej hyperroviny.
- veľkosť (norma) vektora  $\bar{w}$ , zabezpečujúca, že šírka marže je meraná kolmo.

Ak vezmeme do úvahy obmedzenie 2 a rovnicu vzdialenosti medzi dvoma rovnobežnými nadrovinami, môžeme tento tvar rovnice marže prepísať na tento tvar:


$$\frac{2}{\|w\|}$$

Cieľ SVM sa dá formulovať ako nasledovný optimalizačný problém:

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad (3)$$

kde:

- $\|w\|$  predstavuje Euklidovskú normu vektora váh, ktorá udáva jeho veľkosť



Obrázok 2: Vizualizácia cieľa optimalizácie SVM



To vedie k situácii, keď potrebujeme nájsť extrém funkcie za určitých podmienok - konkrétne sa snažíme minimalizovať účelovú funkciu a zároveň zabezpečiť, aby naše riešenie spĺňalo podmienku 2. Na riešenie tohto obmedzeného optimalizačného problému používame Lagrangeove multiplikátory, matematickú techniku, ktorá nám umožňuje transformovať obmedzený optimalizačný problém na neobmedzený tým, že zahrnie obmedzenia priamo do účelovej funkcie [1]. Táto reformulácia nám umožňuje hľadať extrém bez explicitného spracovania obmedzení, čo uľahčuje riešenie problému pomocou štandardných optimalizačných techník:

$$L = \frac{1}{2} \|w\|^2 - \sum L_i [y_i (\bar{w} \cdot \bar{x}_i + b) - 1] \quad (4),$$

kde:

- $L_i \geq 0$  sú Lagrangeove multiplikátory, pričom  $L_i \neq 0$  pre podporné vektory a  $L_i = 0$  pre všetky ostatné body

Aby sme našli extrém funkcie, musíme teraz vypočítať jej derivácie vzhľadom na optimalizačné premenné a nastaviť ich na nulu [2]. Aplikáciou tohto postupu na Lagrangeovu funkciu získame sústavu rovníc, ktorá súčasne spĺňa cieľovú funkciu aj uložené obmedzenia, čo nám umožňuje určiť optimálne riešenie pre deliacu hyperrovinu:

$$\frac{\partial L}{\partial x} = w - \sum L_i \times y_i \times x_i = 0 \quad (5),$$

$$\frac{\partial L}{\partial b} = - \sum L_i \times y_i = 0$$

Z výrazu 5 môžeme vyvodit, že:

$$w = \sum L_i \times y_i \times x_i \quad (6)$$

Po doplnení výrazu 4 o výraz 6 dostaneme túto rovnicu:

$$L = \frac{1}{2} \left( \sum L_i \times y_i \times x_i \right) \left( \sum L_j \times y_j \times x_j \right) - \left( \sum L_i \times y_i \times x_i \right) \left( \sum L_j \times y_j \times x_j \right) - \sum L_i \times y_i \times b + \sum L_i,$$

ktoré potom môžeme zjednodušiť na:

$$L = \sum L_i - \frac{1}{2} \left( \sum_i \sum_j L_i L_j y_i y_j x_i x_j \right) \quad (7)$$

Z rovnice 7 vyplýva, že optimalizačný proces závisí len od bodového súčinu dvoch vektorov  $x$ , ktoré reprezentujú vlastnosti dvoch príkladov. Toto je duálna formulácia SVM, ktorá sa zvyčajne rieši namiesto primárneho problému. Okrem toho sa v oboch vyjadreniach 3 a 7 zaoberáme kvadratickým optimalizačným problémom, čo zabezpečuje konvexný optimalizačný proces a vylučuje možnosť uviaznutia algoritmu v lokálnych maximách.

V mnohých praktických úlohách nie sú dáta lineárne separovateľné. Na riešenie tohto problému využíva SVM techniku, ktorá umožňuje implicitne mapovať dáta do vyššieho rozmeru, kde sa stanú lineárne separovateľnými. V tradičnom SVM pracujeme so skalárnym súčinom dvoch vektorov v pôvodnom priestore [3]:

$$K(x_i, x_j) = x_i \cdot x_j$$

Ak by sme chceli aplikovať transformáciu na vyšší rozmer, museli by sme explicitne vypočítať nové hodnoty všetkých vektorov v tomto priestore, čo je výpočtovo veľmi náročné. Jadrová funkcia nám poskytuje reprezentáciu skalarného súčinu v inom priestore, čím umožňuje vypočítať skalárny súčin bez explicitnej transformácie. Tento princíp je známy ako Kernel Trick a matematicky sa vyjadruje pomocou jadrovej funkcie (kernel function) [3]:

$$K(x_i, x_j) = \varphi(x_i) \cdot \varphi(x_j)$$

kde  $\varphi(x)$  reprezentuje transformáciu dát do vyššieho dimenzionálneho priestoru.

Výber vhodnej jadrovej funkcie je kritický pre úspešnosť modelu, pretože ovplyvňuje jeho schopnosť rozpoznávať vzory a generalizovať na nové dáta. Najčastejšie používané jadrá su:

- Lineárne jadro:  $K(x_i, x_j) = x_i \cdot x_j$
- Polynomiálne jadro:  $K(x_i, x_j) = (x_i \cdot x_j + c)^d$ , kde
  - $d$  je stupeň polynómu
  - $c$  je konštanta na kontrolu flexibility modelu
- Radial Basis Function (RBF) jadro:  $K(x_i, x_j) = \varepsilon \exp\left(\frac{-\gamma \|x_i - x_j\|^2}{2\sigma^2}\right)$ , kde
  - $\gamma$  je parameter, ktorý určuje, ako ďaleko môže bod ovplyvniť iné body v priestore.

Okrem toho existuje ešte jedna technika, ktorá rieši problém nelineárne separovateľných údajov – Soft Margin SVM, rozšírenie základného SVM (Hard Margin SVM), ktoré umožňuje určitú mieru nesprávnej klasifikácie. Týmto spôsobom toleruje podmienku 2 a umožňuje niektorým vzorkám porušiť hranicu marže v záujme lepšej generalizácie modelu. Soft Margin SVM rozširuje Hard Margin zavedením slack premenných  $\varepsilon$  a regularizačného parametra  $C$ .

Matematicky optimalizačný problém pre Soft Margin SVM je definovaný ako[1]:

$$\min_{w,b,\varepsilon} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \varepsilon_i$$

pričom platí:

$$y_i(w_i x + b) \geq 1 - \varepsilon_i; \varepsilon_i \geq 0, kde:$$

- $w$  je vektor váh,
- $x$  je vstupný vektor,
- $b$  je bias (posun hyperroviny),
- $y_i$  sú cieľové označenia,
- $C$  je regularizačný parameter,
- $\varepsilon_i$  sú pomocné slack premenné,

Hodnota  $\varepsilon_i$  sa vypočíta z tohto výrazu:

$$\varepsilon_i = \max(0, 1 - y_i(w_i x + b))$$

pričom určuje, či klasifikácie porušujú rozhodovaciu hranicu a ako výrazne ju porušujú:

- Ak  $\varepsilon_i = 0$ , vzorka je správne klasifikovaná a nachádza sa mimo marže.
- Ak  $0 < \varepsilon_i < 1$ , vzorka je v rámci marže, ale stále správne klasifikovaná.
- Ak  $\varepsilon_i > 1$ , vzorka je nesprávne klasifikovaná.

Ešte jeden kľúčový parameter Soft Margin SVM je regularizačný parameter  $C$ , ktorý kontroluje kompromis medzi maximalizáciou rozpätia a minimalizáciou chyby klasifikácie. Pre hodnoty parametra  $C$  platí [2]:

- Vysoká hodnota  $C$  uprednostňuje presnú klasifikáciu a prísne penalizuje chybné klasifikácie. Môže však viesť k overfittingu, lebo model sa snaží príliš presne oddeliť dáta.
- Nízka hodnota  $C$  uprednostňuje širšiu maržu, umožňuje určitú mieru chybnéj klasifikácie a zlepšuje generalizáciu modelu. Model sa stáva robustnejším, ale môže mať nižšiu presnosť na tréningových dátach.

### 3. Implementácia riešenia

#### 3.1. Spracovanie a analýza dát

Pre tréning a vyhodnotenie modelu bol použitý GTZAN Music Genre dataset z Kaggle. Tento dataset obsahuje rôznorodé hudobné ukážky s pridelenými žánrovými štítkami, čo umožňuje použitie supervidovaného učenia. Dataset pôvodne obsahoval 10 hudobných žánrov, avšak na účely implementácie binárneho klasifikátora bol počet tried zredukovaný na dve, čím sa model sústreďuje na rozlíšenie medzi vybranými žánrami. Aby sa znížila výpočtová náročnosť a zvýšila efektivita modelu, bola vykonaná analýza korelácie medzi jednotlivými príznakmi a cieľovou premennou. Tento krok umožnil výber najvýznamnejších príznakov, čím sa eliminovali menej dôležité vlastnosti a zlepšila sa interpretovateľnosť modelu.

Na základe analýzy boli vybrané tieto kľúčové príznaky:

- Spektrálny centroid – vyjadruje „jasnosť“ zvuku na základe priemernej frekvencie.
- Spektrálna šírka pásma – meria rozptyl frekvencií okolo spektrálneho centroidu.
- Spektrálny rolloff – označuje frekvenciu, pod ktorou je sústredené určité percento celkovej energie signálu.
- Chroma STFT – analyzuje rozloženie hudobných tónov v spektre.
- RMS energia – vyjadruje celkovú silu zvukového signálu.
- MFCCs – modelujú vlastnosti zvuku relevantné pre ľudské vnímanie.

Okrem toho boli kategorické žánrové štítky zakódované do číselných hodnôt, aby boli vhodné na klasifikáciu. Celý proces získavania a predspracovania dát bol implementovaný pomocou knižníc Pandas a NumPy.

#### 3.2. Implementácia algoritmu a dosiahnuté výsledky

Celý algoritmus bol implementovaný ako trieda, ktorá obsahuje nasledovné parametre:

- Váhový vektor  $w$  – určuje orientáciu rozhodovacej hranice.
- Bias  $b$  – posun hyperroviny.
- Parameter  $C$  – regularizačný faktor, ktorý riadi kompromis medzi veľkosťou marže a penalizáciou chybných klasifikácií.
- Rýchlosť učenia  $\eta$  – určuje, akým spôsobom sa aktualizujú váhy počas optimalizácie.

Pred samotným tréningom sa dáta načítajú zo CSV súboru a následne sú rozdelené na trénovaciu a testovaciu množinu. Aby sa zabezpečila správna škálovateľnosť údajov, hodnoty sú

transformované pomocou Min-Max škálovania, čo umožňuje normalizáciu rozsahu vstupných hodnôt. Samotný tréning pozostáva z iteratívnej optimalizácie váh pomocou gradientného zostupu a regularizácie. Aktualizácia váh prebieha podľa nasledujúceho pravidla:

- Ak je vzorka správne klasifikovaná, aplikuje sa len regularizácia:

$$w_j = w_j - \eta(2\lambda w_j)$$

- Ak je vzorka nesprávne klasifikovaná, váhy sa aktualizujú pomocou gradientného zostupu aj regularizácie:

$$w_j = w_j - \eta(2\lambda w_j - yx_{ij})$$

Po ukončení tréningového procesu sú natrénované parametre modelu, konkrétne váhy a bias, uložené do TXT súboru, aby mohli byť neskôr použité pri predikcii.

Keďže ide o klasifikačnú úlohu, na vyhodnotenie výkonu modelu boli použité štandardné metriky: accuracy, precision, recall a F1-score. Implementovaný model dosiahol presnosť 97,5 %, precision 1, recall 0,95 a F1-score 0,974. Tieto výsledky naznačujú, že model veľmi efektívne rozlišuje medzi dvoma vybranými triedami v rámci použitých tréningových a testovacích údajov.


### 3.3. Implementácia predikčného skriptu

Predikčná časť systému načítava parametre natrénovaného modelu z TXT súboru, extrahuje príznaky zo vstupných zvukových súborov a vykonáva klasifikáciu na základe získaných hodnôt. Po extrakcii sa vstupné dáta normalizujú pomocou Min-Max škálovania, aby boli v rovnakom rozsahu ako tréningové vzorky. Následne sa vypočíta rozhodovacia funkcia. Na základe znamienka výslednej hodnoty sa určuje predikovaná trieda zvukového súboru. Skript následne vygeneruje výstup s predikovaným žánrom a umožňuje jeho ďalšie spracovanie alebo vizualizáciu.

### 3.4. Implementácia používateľského rozhrania

Používateľské rozhranie bolo navrhnuté tak, aby umožnilo jednoduchú interakciu so systémom klasifikácie hudobných žánrov. Na jeho implementáciu bola použitá knižnica CustomTkinter, ktorá poskytuje moderný a flexibilný vzhľad GUI prvkov.

Rozhranie obsahuje základné ovládacie prvky na výber a analýzu súboru. Používateľ si môže manuálne nahráť zvukový súbor zo svojho zariadenia prostredníctvom tlačidla "Browse", čím sa načíta vybraný súbor do systému. Následne má používateľ možnosť spustiť klasifikáciu kliknutím na tlačidlo "Predict Genre". Po jeho stlačení systém extrahuje relevantné príznaky zo zvukového súboru a vykoná predikciu na základe natrénovaného modelu. Po dokončení klasifikácie sa predikovaný hudobný žáner zobrazí na obrazovke. Používateľ môže následne nahráť nový súbor a vykonať ďalšiu predikciu rovnakým spôsobom.



Obrázok 3: Režim celej obrazovky AlcoustIQ

Okrem základnej funkcionality obsahuje rozhranie aj tlačidlo "Show Instructions", ktoré po stlačení zobrazí krátky návod na používanie systému v spodnej časti obrazovky. Tento návod poskytuje používateľovi stručné informácie o tom, ako nahrať súbor, spustiť analýzu a interpretovať výsledky.

Súčasťou rozhrania je aj tlačidlo "Clear", ktoré umožňuje odstrániť aktuálne zvolený súbor zo vstupného poľa, vyčistiť štítok s predikovaným žánrom a skryť zobrazené inštrukcie. Táto funkcionality umožňuje používateľovi rýchlo obnoviť aplikáciu a vykonať novú predikciu bez potreby reštartovania rozhrania.

## Záver

Táto práca sa zaoberala implementáciou binárneho klasifikátora hudobných žánrov pomocou Support Vector Machine (SVM). Bol použitý GTZAN Music Genre Dataset, pričom na základe analýzy korelácie boli vybrané najvýznamnejšie príznaky. Tréning modelu prebiehal v C++ implementácii SVM algoritmu, kde boli optimalizované váhy pomocou gradientného zostupu a regularizácie. Model dosiahol 100 % presnosť vo všetkých vyhodnocovacích metrikách.

Používateľské rozhranie umožňuje jednoduchú interakciu so systémom a podporuje manuálne načítanie súborov, spustenie predikcie a zobrazenie výsledkov.

Ďalší vývoj môže zahŕňať rozšírenie na viactriednu klasifikáciu, použitie pokročilejších modelov hlbokého učenia (CNN, LSTM) a integráciu pokročilejších techník extrakcie príznakov pre presnejšiu analýzu zvukových dát.

## Zoznam použitej literatúry

- [1]. MIT OpenCourseWare. *6.034 Tutorial 5: Support Vector Machines and Boosting*. Massachusetts Institute of Technology, 2010. [Online]. Available: <http://ocw.mit.edu>
- [2]. MIT OpenCourseWare. Patrick Winston. 16. Learning: Support Vector Machines. YouTube. 2014. [Online]. Available: <https://www.youtube.com/watch?v=PwhiWxHK8o&t=2540s>
- [3]. Scikit-learn Developers. Support Vector Machines. – *Scikit-learn Documentation*. Scikit-learn, 2024. [Online]. Available: <https://scikit-learn.org/stable/modules/svm.html>